


Statistikworkshop

Dr. Stefan Lars Reckelkamm

Donnerstag, 24. und Freitag, 25. September 2026



Zeitlicher Rahmen und Inhalt

Online-Skript: stefanrecke.github.io/statistikworkshop

Donnerstag · 13:15–15:45

Querschnitt: NHANES

- R und Daten: Software, Erhebung, fehlende Werte
- Daten beschreiben und Zusammenhänge messen
- Testen und das passende Modell wählen
- Studiendesign, Bias und Confounding
- Regression und Vorhersage

Freitag · 11:00–13:00

Längsschnitt: Implantatverlust

- Zeit bis zum Ereignis: Kaplan-Meier und Cox
- Clustering
- RCT gegen Routinedaten
- Ihre Vorhaben und Fragen (ca. 45 Min.)

01

Werkzeug: R und Daten


Software, Arbeitsablauf, Datenerhebung und fehlende Werte

R und RStudio

Positron und KI

Excel-Erhebung

Fehlende Werte



R, SPSS und andere Programme

Statistiksoftware ... und Excel.

Frei verfügbar

Open Source, große Gemeinschaft, Pakete für nahezu jede Methode.

Bedienung über Code – dadurch ist jede Analyse nachvollziehbar und wiederholbar.



Lizenzpflichtig

Etabliert, teils mit Menüs bedienbar – dafür Lizenzkosten und Bindung an einen Anbieter.



Excel ist kein Statistikprogramm – aber aus der Datenerfassung nicht wegzudenken. Viele Datenbanken laufen noch darüber.

Grober Aufbau einer wissenschaftlichen Arbeit

Und wo Ihnen Excel begegnen wird.

1 Planung

Frage, Design, Endpunkt, Fallzahl

2 Daten sammeln

Erhebungsbogen, Codebuch, fehlende Werte kodieren

3 Daten aufbereiten

prüfen, bereinigen, Variablen ableiten

4 Daten auswerten

beschreiben, Modell wählen, schätzen

5 Berichten

nach Leitlinien wie STROBE oder CONSORT



RStudio: vom Einlesen zur ersten Grafik

Video

Positron mit KI-Assistent


Video

Skills: der KI seinen Stil aufdrücken

Video

Warum Aufbereiten schon Statistik ist

Fehlende Werte im NHANES-Datensatz (N = 16.588), Auswahl aus dem Skript



Die eigentliche Frage

Nicht, *ob* Werte fehlen – sondern **warum** sie fehlen.

Der Parodontalbefund fehlt bei rund der Hälfte: Laut Skript wurde er nur in einer Teilstichprobe erhoben.

Ist das harmlos? Das hängt davon ab, wie diese Teilstichprobe zustande kam.

Drei Gründe, warum Werte fehlen

Die Begriffe gehen auf Rubin (1976) zurück.



MCAR

missing completely at random

völlig zufällig

Beispiel: Ein Befundbogen geht verloren.

Folge: Weniger Power, aber keine Verzerrung.



MAR

missing at random

zufällig, gegeben das Bekannte

Beispiel: Ältere erscheinen seltener zur Nachuntersuchung – das Alter ist erfasst.

Folge: Löschen kann verzerren. Multiple Imputation oder Gewichtung mit den bekannten Merkmalen hilft.



MNAR

missing not at random

hängt vom fehlenden Wert ab

Beispiel: Wer schwere Parodontitis hat und sich schämt, lehnt die Untersuchung ab.


Folge: Aus den Daten allein nicht zu reparieren.

Mittelwert einsetzen: Scheingenauigkeit


	n	Mittelwert	SD
Complete Case	14.879	28,54	6,14
Mean Imputation	16.588	28,54	5,82

Der Mittelwert bleibt gleich, die Streuung schrumpft künstlich: Alle ergänzten Werte sitzen exakt auf dem Mittelwert. Später folgen zu enge Konfidenzintervalle.

Complete Case



Mean Imputation



simulierte Werte, schematisch


Besser (bei MAR)

Multiple Imputation: mehrere plausible Werte je Lücke

02

Daten beschreiben

Merkmalstypen, Maße und Zusammenhänge



Im Skript: NHANES Kapitel 4

Teilbereiche der Epidemiologie

In welchen Bereich passt Ihre Fragestellung?

Deskriptiv

Wie häufig, bei wem, wann?


Anteil Erkrankter (Prävalenz), Neuerkrankungen (Inzidenz), Krankheitsverlauf



Analytisch

Warum?

Krankheitsursachen: Risiko- und Schutzfaktoren aus Genetik, Umwelt und Lebensweise



Experimentell

Wirkt es?

Interventionen umsetzen und bewerten, z. B. Prävention oder Versorgung



Merkmaltypen und Skalenniveaus

Wie Sie Daten zusammenfassen, hängt von der Art des Merkmals ab.

QUALITATIV – ohne „mathematischen Wert“

Nominal

Kategorien ohne Reihenfolge

Augenfarbe, Geschlecht, Raucherstatus

Ordinal

Reihenfolge, aber keine gleichen Abstände

gut – besser – am besten, Schulnoten, Furkationsgrad

QUANTITATIV

Metrisch

gleiche Abstände, teils echter Nullpunkt

10 Grad wärmer, doppelt so alt, Sondierungstiefe in mm




FIGURE 3 Prevalence of total, severe, and nonsevere periodontitis by smoking status in dentate adults aged 30-79 years: National Health and Nutrition Examination Survey, 2009-2014 (N = 10,683). Total (any) periodontitis: severe, moderate, or mild periodontitis; nonsevere periodontitis: moderate or mild periodontitis

Parodontitis nach Rauchstatus, NHANES 2009–2014 – Eke et al. 2020, Periodontology 2000

Maße für qualitative Merkmale



Anzahl

absolute Häufigkeit



Prävalenz

Anteil der Erkrankten zu einem Zeitpunkt



Inzidenz

Neuerkrankungen pro Zeiteinheit



Odds (Chance)

Wahrscheinlichkeit dafür ÷ Wahrscheinlichkeit dagegen

Eine 6 würfeln



Wahrscheinlichkeit: **1 von 6** $\approx 17\%$

Odds: **1 : 5** = 0,2 – eine günstige gegen fünf ungünstige

Nicht alles, was sich rechnen lässt, ist sinnvoll: 5 Genesene und 5 Verstorbene, kodiert als 0 und 2 – der Mittelwert ist 1 („krank“). Sind im Mittel alle krank?

4.1 Einzelne Merkmale grafisch darstellen

stefanrecke.github.io/statistikworkshop/NHANES_Auswertung.html

Maße für quantitative Merkmale

Lagemaße

Mittelwert – für symmetrisch verteilte Merkmale

Median – teilt die Stichprobe in zwei Hälften

Streuungsmaße

Varianz – mittleres Abweichungsquadrat vom Mittelwert

Standardabweichung – Wurzel der Varianz, in der Einheit der Daten

Verteilungsform

symmetrisch oder schief – der Attachmentverlust ist stark rechtsschief (Schiefe 2,6 im Skript)



Körpergröße ist das perfekte metrische Merkmal: echter Nullpunkt, beliebig fein messbar.

Der Durchschnitt kann täuschen




Bild: Jono Hey, sketchplanations.com (CC BY-NC 4.0)

Durchschnittliche Tiefe: 3 Fuß

- Ein Mittelwert allein verschweigt die Streuung
- Zeigen Sie immer auch Verteilung und Spannweite – am besten grafisch
- Bei schiefen Daten: Median und Quartile berichten

Vierfeldertafel: Risiko, RR und Odds Ratio

Beispiel aus dem Skript: Diabetes bei Menschen mit und ohne Parodontitis

	Diabetes ja	Diabetes nein	gesamt	Risiko
Parodontitis ja	199	988	1.187	16,8 %
Parodontitis nein	578	6.290	6.868	8,4 %

Risiko = Anteil mit Diabetes in der jeweiligen Zeile

8,3

Risikodifferenz (RD)

$16,8 \% - 8,4 \% = 8,3 \text{ Prozentpunkte}$

1,99

Relatives Risiko (RR)

$16,8 \% \div 8,4 \%$

2,19

Odds Ratio (OR)

$(199 \times 6.290) \div (988 \times 578)$



Bei häufigen Ereignissen liegt die Odds Ratio weiter von 1 entfernt als das relative Risiko – beide nicht verwechseln.

Gleiche relative, ungleiche absolute Wirkung

Wurzelkanalbehandlung: Zahnverlust nach 5 Jahren mit Sealer A oder B – zwei konstruierte Szenarien

Szenario 1: häufiges Ereignis

Sealer B  36 %

Sealer A  24 %

33 %

relative
Risikoreduktion

12

Prozentpunkte
absolute Reduktion

9

Behandlungen je
verhindertem
Verlust

Szenario 2: seltenes Ereignis

Sealer B  9 %

Sealer A  6 %

33 %


relative
Risikoreduktion

3

Prozentpunkte
absolute Reduktion

34

Behandlungen je
verhindertem
Verlust



*Umschüttversuch: gleiche Menge,
anderes Glas*



Die relative Reduktion klingt in beiden Fällen gleich. Wie viele Patientinnen und Patienten profitieren, zeigen erst **absolute Differenz** und **NNT**.



Pause

Weiter in 5 Minuten?

Zum Nachdenken

Welches Outcome hat Ihr eigenes Vorhaben?

Welche Werte kann es annehmen – alles, nur positive, Prozent, ganze Zahlen, ja/nein oder Zeit bis zum Ereignis?

03

Testen und Modellwahl

Hypothesen, Fehlerarten und das passende Modell für Ihr Outcome


Hypothesen

α und β

Welcher Test?

Drei Leitfragen

Spickzettel



Im Skript: NHANES Kapitel 5–6

Testen: eine Hypothese prüfen

Vom Stichprobenbefund auf die Grundgesamtheit schließen – mit kontrollierbarem Irrtum

1. Theoretischen Hintergrund erarbeiten
2. Nullhypothese H_0 und Alternativhypothese H_1 festlegen
3. Daten sammeln und statistisch analysieren

Die Fallzahl hängt ab von

- α (meist 5 %) und Power $1 - \beta$ (meist 80 %)
- Art der Daten und des Tests
- Größe des Effekts, den Sie finden wollen

In Wahrheit ...		
	kein Unterschied (H_0 stimmt)	ein Unterschied (H_0 falsch)
Test nicht signifikant	richtig	Fehler 2. Art β , z. B. 20 %
Test signifikant	Fehler 1. Art α , meist 5 %	richtig Power, z. B. 80 %



Fehlentscheidungen sind nicht ausgeschlossen, aber kontrollierbar. Berichten Sie den p-Wert immer zusammen mit dem Konfidenzintervall.


Welcher Test passt?

Unabhängige Stichprobe



Unverbunden: verschiedene Personen in den Gruppen

Abhängige Stichprobe



Verbunden: dieselbe Person mehrfach gemessen – vorher/nachher, Split-Mouth

Nach Funktion

Lagetest (Mittelwert, Median) · **Anteilstest** (Prozente) · **Unabhängigkeitstest** (χ^2) · **Anpassungstest** (Verteilung)

Im Skript

- **Ein-Stichproben-t-Test:** mittlerer BMI gegen den WHO-Wert 21,7 (6.1)
- **Mann-Whitney-U-Test:** Attachmentverlust bei Rauchern und Nichtrauchern (6.2)

6.1–6.2 t-Test und Mann-Whitney-U-Test

stefanrecke.github.io/statistikworkshop/NHANES_Auswertung.html

Drei Leitfragen bei jedem Outcome

Nicht der Rechenweg, sondern die Art der Zahl entscheidet über das Modell.

1 Wertebereich

Welche Werte kann das Outcome annehmen?

alles · nur positiv · 0–100 % · ganze Zahlen · ja/nein · Zeit bis zum Ereignis

2 Form der Verteilung

Symmetrisch oder schief?

Häufungen an den Rändern? Viele Nullen, viele 0 % oder 100 %?

3 Gewünschte Aussage

Was will ich sagen?

Differenz in Einheiten („0,3 mm mehr“) · relative Änderung („12 % höher“) · Wahrscheinlichkeit oder Risiko

5 Modellwahl: das richtige Werkzeug für die Situation

stefanrecke.github.io/statistikworkshop/NHANES_Auswertung.html

04

Studiendesign und Verzerrung

Beobachten oder zuteilen – zufällige und systematische Fehler,
Confounding


Designs

Randomisierung

Bias

Confounding

Variablenauswahl



Im Skript: NHANES 6.3

Beobachtende Studiendesigns

Die Grundlage bleibt oft das systematische Beobachten.



Querschnitt

das Hier und Jetzt

Einmalige Erhebung:
Häufigkeiten und
Zusammenhänge – ohne
zeitliche Abfolge.

Beispiel: NHANES



Kohorte

*Gesunde durch die Zeit
begleiten*

Mehrere Zeitpunkte:
Neuerkrankungen und
Risikofaktoren.

Beispiel: SHIP



Fall-Kontrolle

der Blick zurück

Von Erkrankten und
Kontrollen rückwärts zur
Exposition – gut bei seltenen
Erkrankungen.

**Beispiel: Mobiltelefon und
Hirntumor**



Ökologisch

aggregierte Daten

Gruppen statt Personen, z. B.
Regionen oder Jahre.

**Beispiel: Zahnarztdichte je
Bundesland**

Durch Zufall vergleichbar: Randomisierung

Warum randomisierte kontrollierte Studien (RCTs) so beliebt sind



Austauschbarkeit

Die Gruppen könnten die Plätze tauschen: Bekannte und unbekannte Störgrößen sind im Mittel gleich verteilt.



Verblindung

Weder Proband noch Behandler kennen die Gruppe: kein Placebo-, Nocebo- oder Behandlungseffekt.




Stärkste kausale Evidenz


Confounding ist per Design weitgehend ausgeschlossen.

Nachteile: zeit- und kostenaufwendig, für seltene Erkrankungen kaum geeignet, ethisch oft nicht durchführbar – deshalb müssen wir mit den Fehlern der Beobachtungsdesigns umgehen können.

Zufällige und systematische Fehler



präzise und richtig



unpräzise, im Mittel richtig



präzise, aber daneben

Zufälliger Fehler

- z. B. klassische Messfehler
- wird mit größerer Stichprobe kleiner
- beschrieben durch Standardfehler, Konfidenzintervall, p-Wert

Systematischer Fehler (Bias)

- z. B. falsch geeichtes Gerät, verzerrte Auswahl
- entsteht in Design und Auswertung
- wird durch mehr Daten nicht kleiner

Systematische Fehler: Beispiele

Sie werden mit wachsender Stichprobe nicht kleiner – typische Folge: Korrelation ist nicht Kausalität.



Selektionsbias

Die Auswahl der Teilnehmenden ist verzerrt – etwa eine gesündere Kontrollgruppe oder der Healthy-Worker-Effekt bei Studien an Beschäftigten.




Informationsbias

Die Erhebung ist verzerrt – etwa weil Erkrankte sich genauer an frühere Expositionen erinnern (Recall-Bias).



Confounding

Eine Drittvariable beeinflusst Exposition und Outcome zugleich – dazu gleich mehr.



Selektionsbias in einem Bild





Bild: Jono Hey, sketchplanations.com (CC BY-NC 4.0)

500 Antworten – und 99,8 % antworten gern auf Umfragen.

- Wer nicht antwortet, fehlt in der Statistik
- Dasselbe Prinzip wie bei fehlenden Werten: Das Fehlen hängt mit dem Gemessenen zusammen
- Fragen Sie bei jeder Studie: Wer ist drin – und wer nicht?

Confounding

Der Zusammenhang geht ganz oder teilweise auf eine Drittvariable zurück.



DAG: Pfeil = angenommene Ursache, kein Pfeil = kein direkter Einfluss

Adjustieren

Confounder als Variable ins Regressionsmodell aufnehmen – der Effekt wird „bei gleichem Rauchstatus“ geschätzt.

Cave: Mediatoren


Liegt B auf dem Weg von A nach Y, nimmt die Adjustierung für B einen Teil des Effekts heraus.



6.3 Confounding am Beispiel Rauchen


stefanrecke.github.io/statistikworkshop/NHANES_Auswertung.html

Korrelation ist nicht Kausalität



Scheidungsrate in Maine und Margarineverbrauch

Grafiken: Tyler Vigen, tylervigen.com (CC BY 4.0)




Käseverbrauch und Tod durch Verheddern im Bettlaken

Variablenauswahl: Wissen vor Statistik

- Statistische Auswahlverfahren – nach p-Wert oder Änderung des Schätzers – gelten als überholt
- Für einen DAG ist medizinisches Vorwissen unverzichtbar
- Eine signifikante Variable in einem Vorhersagemodell muss keine Ursache sein

Das Feuerzeug in der Tasche



Was passiert, wenn Sie nur Nichtraucher untersuchen?

Der Zusammenhang verschwindet: Das Feuerzeug war nur ein Marker für das Rauchen.

Erklären oder vorhersagen?

Dasselbe Werkzeug, zwei Zwecke – das Ziel bestimmt Variablenauswahl und Bewertung.



Erklären (kausal)

- **Frage:** Wirkt X auf Y?
- **Variablen:** eine Zielexposition, dazu Confounder nach DAG – keine Mediatoren
- **Bewertung:** Ist der Effekt unverzerrt?
- **Beispiel:** Rauchen und Parodontitis



Vorhersagen (prädiktiv)

- **Frage:** Wie hoch ist das Risiko dieser Person?
- **Variablen:** verfügbare, gut messbare Merkmale – das Feuerzeug darf hinein
- **Bewertung:** Diskrimination, Kalibrierung, klinischer Nutzen
- **Beispiel:** Parodontitis-Risiko aus Alter, Geschlecht, Rauchen, Diabetes

05


Regression und Vorhersage

Von der Geraden zum Prädiktionsmodell: Diskrimination, Kalibrierung, Validierung, Nutzen

Lineare Regression

Logistische Regression

Gütekriterien




Im Skript: NHANES Kapitel 7

Regression: vom Galton-Effekt zur Geraden

Rückschritt zur Mitte



Francis Galton (1822–1911): Söhne sehr großer und sehr kleiner Väter weichen weniger vom Durchschnitt ab als ihre Väter.

- Die Regression beschreibt den Zusammenhang zwischen Einflussgröße X und Zielgröße Y mit einer Gleichung
- Kleinste Quadrate: Die Gerade minimiert die quadrierten Abstände der Punkte (Residuen)
- R^2 = Anteil der Streuung, den das Modell erklärt – bei 1 liegen alle Punkte auf der Geraden



Logistische Regression: wenn das Outcome ja/nein ist

- Binäres Outcome: bösartig oder nicht, Implantat verloren oder nicht
- Vorhergesagt wird eine Wahrscheinlichkeit – die S-förmige logistische Funktion hält sie zwischen 0 und 1
- Ergebnis: Odds Ratios. Die Koeffizienten selbst sind logarithmierte Odds Ratios: $\exp(\beta) = OR$
- Geschätzt wird mit Maximum Likelihood statt kleinster Quadrate



Das Prädiktionsmodell im Skript

Logistische Regression: Parodontitis aus Alter, Geschlecht, Rauchen und Diabetes

8.044

Personen mit
vollständigen Daten

1.584

davon mit
Parodontitis

317

Events pro Variable
(Faustregel: ≥ 10)

0,696

AUC
(Diskrimination)

Prädiktor	Odds Ratio
Alter (je Jahr)	1,04
Männlich	1,65
Früher geraucht	1,30
Aktuell Raucher	2,98
Diabetes	1,42

Referenz: nie geraucht, kein Diabetes

Vier Fragen an jedes Vorhersagemodell

1

Trennt es?

Diskrimination

2

Stimmen die Wahrscheinlichkeiten?

Kalibrierung

3

Gilt es auch anderswo?

Validierung

4

Hilft es bei Entscheidungen?


klinischer Nutzen

Diskrimination: Kann das Modell trennen?

AUC: Fläche unter der ROC-Kurve (auch c-Statistik)

Nehmen Sie zufällig eine Person **mit** und eine **ohne** Parodontitis. Die AUC ist der Anteil solcher Paare, in denen die erkrankte Person das höhere vorhergesagte Risiko bekommt.

0,696 im Skript: 70 % der Paare richtig sortiert




Nur die Reihenfolge zählt

Die AUC prüft, ob Kranke vor Gesunden einsortiert werden – nicht, ob die Zahlen stimmen.

Würde das Modell alle Risiken verdoppeln, bliebe die AUC gleich.

Kalibrierung: Stimmen die Wahrscheinlichkeiten?



Wie der Wetterbericht

An Tagen mit 30 % Regenvorhersage sollte es an etwa 3 von 10 Tagen regnen.

- **Calibration-in-the-large:** Stimmt das mittlere Risiko? (ideal 0)
- **Calibration slope:** Sind die Vorhersagen zu extrem? (ideal 1; unter 1 typisch bei Überanpassung)
- **Im Skript:** Slope ≈ 1 (nach Bootstrap-Korrektur 0,993)



Ein Modell kann gut trennen und trotzdem alle Risiken überschätzen. Für die Beratung von Patientinnen und Patienten zählt die Kalibrierung.

Interne und externe Validierung



Intern: Wie geschönt ist das Modell?

- Ein Modell passt immer am besten zu den Daten, aus denen es stammt (Optimismus)
- Bootstrap: das Modell vielfach auf Stichproben neu schätzen und am Original prüfen
- **Im Skript:** AUC 0,696 → 0,694 – bei 317 Events pro Variable kaum Überanpassung



Extern: Funktioniert es woanders?

- Neue Daten aus anderer Zeit, an anderem Ort oder aus anderer Population
- z. B. das NHANES-Modell in einer deutschen Kohorte – oder in Ihrer Praxis
- Erst die externe Validierung zeigt, ob sich das Modell übertragen lässt

7 Prädiktionsmodell für Parodontitis

stefanrecke.github.io/statistikworkshop/NHANES_Auswertung.html

Vier Sätze zum Mitnehmen

1

Erst die Frage, dann das Modell

Wertebereich, Verteilung und gewünschte Aussage legen das Modell fast fest.

2

Aufbereiten ist schon Statistik

Wie Sie mit fehlenden Werten umgehen, verändert Ihre Ergebnisse.

3

Beschreiben, erklären, vorhersagen

Jedes Ziel verlangt eine andere Variablenauswahl und andere Gütekriterien.

4

Das Design ist mächtiger als das Modell

Confounding lässt sich durch Randomisierung vermeiden, durch Adjustierung nur verringern.

Morgen: Zeit bis zum Ereignis, Clustering, RCT gegen Routinedaten


Tag 2 · Freitag, 25. September 2026 · 11:00–13:00

Zeit, Cluster und Ihre Fragen

Längsschnitt am Beispiel Implantatverlust

Dr. Stefan Lars Reckelkamm

Statistikworkshop · DG Paro Young Experts Training



06

Zeit bis zum Ereignis

Überlebenszeitanalyse am Beispiel Implantatverlust

Zensierung


Kaplan-Meier

Log-Rank

Hazard Ratio

Cox

PH-Annahme



Im Skript: Studiensimulation, Teil A

Überlebenszeitanalyse: worum es geht

Ursprung: demografische Studien zur Lebenserwartung



Logistische Regression

Ob das Ereignis eintritt – ja oder nein




Überlebenszeitanalyse

Wann es eintritt – Zeit bis zum Ereignis oder bis zum Ende der Beobachtung

Beispiele aus der Zahnmedizin

- Zeit vom Einsetzen einer Prothese bis zur ersten Reparatur
- Zeit vom Legen einer Füllung bis zur Erneuerung
- Zeit von der Implantation bis zum Verlust
- Ob zahnlose Menschen früher sterben

Zensierung: wenn das Ende fehlt



Wir kennen die genaue Zeit bis zum Ereignis nicht – nur, dass sie länger ist als die Beobachtung.

Ursachen


- Studienende ohne Ereignis
- Teilnahme beendet oder Kontakt verloren (loss to follow-up)
- Tod aus anderer Ursache – streng genommen ein konkurrierendes Ereignis (competing risk)

Besondere Verzerrung: Immortal Time Bias

Kinder mit Herztransplantation mussten bis zur Transplantation überleben. Diese „unsterbliche“ Zeit darf nicht der Behandlung gutgeschrieben werden.

Sterbetafel und Kaplan-Meier-Kurve

$t_{(j)}$	n_j	m_j	q_j
0	21	0	0
1	21	2	0
2	19	2	0
3	17	1	0
4	16	2	0
5	14	2	0
8	12	4	0
11	8	2	0
12	6	2	0
15	4	1	0
17	3	1	0
22	2	1	0
23	1	1	0



- Woche 1: 19 von 21 leben,
Woche 2: 17 von 19 ...
- Die Stufen zeigen den Anteil noch ohne Ereignis
- Zensierungen verkleinern die Risikomenge, ohne eine Stufe zu erzeugen

Kritisch lesen: Überlebensraten in der Werbung

Auszug aus der Werbebroschüre eines Implantatherstellers

Referent	Zeit (Jahre)	Implantate	Verluste	Überlebensrate
Ackermann/Kirsch (GER)	7	3.588	35	98,6%
Babbush (USA)	7	273	3	98,9%
Lin (CHN)	4,5	3.374	22	99,34%
Singer (GER)	5	364	3	99,26%
Watanabe (JPN)	5	552	7	98,6%

Tab. 1 Beim 1. Internationalen CAMLOG Kongress 2006 in Montreux wurden Langzeitergebnisse bis zu 7 Jahren präsentiert. Die kumulierte Anzahl der Implantate betrug 8.251. Die Überlebensrate lag höher als 98,5 %.

- „Kumulierte Überlebensrate über 98,5 %“ – über welchen Zeitraum? Beobachtet wurden 4,5 bis 7 Jahre
- Wurden alle Implantate zur gleichen Zeit gesetzt – und wie wurden Zensierungen behandelt?
- Ab wann wird gezählt: ab Insertion oder erst nach der Einheilung?
- Einfache Anteile ($\text{Verluste} \div \text{Implantate}$) übergehen die Zensierung

Log-Rank-Test und Hazard Ratio



Log-Rank-Test

- Der gebräuchlichste Test: Unterscheiden sich die Kaplan-Meier-Kurven zweier oder mehrerer Gruppen?
- Nicht signifikant heißt: nicht genug Hinweise auf einen Unterschied – nicht: kein Unterschied



Hazard und Hazard Ratio

- **Hazard:** momentane Ereignisrate derer, die noch gefährdet sind
- **Hazard Ratio:** Quotient zweier Hazards – ähnlich zu lesen wie ein relatives Risiko: HR 2,3 heißt, die Ereignisrate ist 2,3-mal so hoch
- **Patients at risk:** noch unter Beobachtung und ereignisfrei – ihre Zahl bestimmt die Breite der Konfidenzintervalle

Cox-Regression

Mehrere Einflussgrößen gleichzeitig – der Schätzer ist die Hazard Ratio

- Schätzt den Einfluss einer oder mehrerer Variablen auf die Zeit bis zum Ereignis
- Die Größe des Einflusses ist die Hazard Ratio: < 1 schützt, > 1 schadet

Im RCT des Skripts


HR 0,78

95 %-KI 0,65–0,94 · $p = 0,007$

Vitamin-D-Gabe gegen keine Gabe, 2.045 Implantate, 482 Verluste. Die Verlustrate sinkt im Mittel um rund 22 % – ohne Adjustierung, weil randomisiert.

Die Proportional-Hazards-Annahme

Cox nimmt an: Die Hazard Ratio ist über die gesamte Beobachtungszeit gleich.




- **Prüfen:** Schoenfeld-Residuen (cox.zph) statt Augenmaß – im Skript $p = 1,4 \times 10^{-5}$, die Annahme ist verletzt
- **Auswege:** Zeit aufteilen (wie im Skript), stratifizieren, zeitabhängige Koeffizienten, ...

07

Clustering

Wenn Beobachtungen zusammenhängen

Designeffekt



Im Skript: Frailty-Modell


Clustering: wenn Beobachtungen zusammenhängen

Stellen im Zahn, Zähne im Mund, Implantate im Patienten, Patienten in Praxen


Patient 1




Patient 2



Patient 3



Patient 4



... 40 Patienten × 6 Zähne = 240 Zähne

Teil A – Die randomisierte Studie (RCT)

stefanrecke.github.io/statistikworkshop/Ueberlebensanalyse_Implantate.html

08

RCT gegen Routinedaten


Dieselbe Frage, zwei Datenquellen – und was Adjustierung leisten kann

Tabelle 1

DAG

Adjustierung

Table-2-Fallacy



Im Skript: Studiensimulation, Teil B

Gleiche Frage, andere Daten

Vitamin D und Implantatverlust – Teil A (RCT) und Teil B (Routinedaten) im Skript




RCT: Gabe per Zufall

Tabelle 1 balanciert (Alter 63 gegen 61 Jahre). Rohschätzer unverzerrt, kausal lesbar.



Routinedaten: Spiegel gemessen

Tabelle 1 unbalanciert: Mit Mangel im Median 67, ohne 59 Jahre alt. Adjustierung nötig.



Routinedaten: HR des Vitamin-D-Mangels je nach Adjustierung

Teil B – Beobachtungsdaten

stefanrecke.github.io/statistikworkshop/Ueberlebensanalyse_Implantate.html


09

Ihre Vorhaben, Ihre Fragen

Fünfzehn Einreichungen – und wiederkehrende Muster

Fünf Fragen

Fragen-Navigator



Reservefolien über den Navigator

Fünf Fragen, die jedes Vorhaben einordnen

1 Beschreiben, erklären oder vorhersagen?

Das Ziel bestimmt Variablenauswahl und Gütekriterien.

2 Wer hat zugeteilt?

Zufall (RCT), Behandelnde (Indikation) oder niemand (Beobachtung)?

3 Was ist die Analyseeinheit?

Person, Zahn, Stelle, Implantat – und wie sind sie verschachtelt?

4 Wo steckt die Zeit?

Querschnitt, vorher-nachher, wiederholt oder Zeit bis zum Ereignis?

5 Was ist der eine primäre Endpunkt?

Vorab festgelegt, scharf definiert, klinisch relevant.

Ein Idee, viele Namen

Mehrere Fachrichtungen haben für dieselbe Idee eigene Namen erfunden.

Linear Mixed Model

Biostatistik

Random-Intercept-Modell

Epidemiologie

Mehrebenenmodell

Sozialwissenschaften

Hierarchisches lineares Modell

Bildungsforschung

Random-Effects-Modell

Ökonometrie

Varianzkomponentenmodell

Statistik

Messwiederholungs-ANOVA

klassische Versuchsplanung

Frailty-Modell

Überlebenszeitanalyse

Gemeinsamer Kern

Messungen hängen zusammen: Stellen im Zahn, Zähne im Mund, Implantate im Patienten.

Patient 1



Patient 2



Patient 3



Patient 4



Sie müssen die Namen nicht auswendig lernen. Erkennen Sie das Problem – den passenden Namen finden Sie dann, auch mit KI.

Was bleibt

1

Erst das Problem, dann das Modell

Drei Leitfragen und fünf Einordnungsfragen ersetzen das Auswendiglernen von Namen.

2

Die Analyseeinheit entscheidet mit

Clustering und Messwiederholung gehören ins Modell – sonst entsteht Scheingenauigkeit.

3

Zeit ist eine eigene Dimension

Zensierung und nicht konstante Effekte verlangen Überlebenszeitmethoden, keine Anteile.

4

Design schlägt Adjustierung

Randomisierung beseitigt Confounding; in Routinedaten hilft nur gezielte, DAG-geleitete Adjustierung.

Vielen Dank

Fragen, Hinweise und Fehler im Skript sind jederzeit willkommen.

Dr. Stefan Lars Reckelkamm



Mit freundlicher
Unterstützung von

meridol[®]

